

T.C.
ESKİŞEHİR OSMANGAZİ ÜNİVERSİTESİ MÜHENDİSLİK
MİMARLIK FAKÜLTESİ



MAKİNE ÖĞRENMESİ
152118633

2025-2026 BAHAR YARIYILI

Ağ Anomali Tespiti

PROJE RAPORU - 1

Grup No: 6

Grup Üyeleri

Çağrı Elagöz - 152120211097

Yusuf Özgöçmen - 152120221093

1. GİRİŞ.....	3
1.1. Modern Ağ Yapılarında Güvenlik İhtiyacı ve Tehdit Dinamikleri.....	3
1.2. Klasik Saldırı Tespit Sistemlerinin Sınırları.....	3
1.3. Davranışsal Karakterizasyon ve Anomali Tespiti.....	3
1.4. Makine Öğrenmesi Yöntemlerinin Kullanım Motivasyonu.....	4
1.5. Çalışmanın Kapsamı ve Genel Hedefler.....	4
2. AĞ GÜVENLİĞİ VE SALDIRI MEKANİZMALARININ TEKNİK ANALİZİ.....	4
2.1. Protokol Katmanları ve Güvenlik Açıkları.....	4
2.2. Temel Saldırı Türlerinin İşleyiş Mantiği.....	5
2.2.1. DoS ve DDoS Ataklarında TCP İstismarı.....	5
2.2.2. Port Tarama ve Keşif Faaliyetleri.....	5
2.2.3. Brute Force ve Periyodik Akışlar.....	5
2.3. Saldırı Tespit Veri Setlerinin Genel Yapısı.....	5
3. BİLİMSEL YAZIN TARAMASI.....	6
3.1. Ağ Güvenliği Veri Setlerinin Tarihsel Gelişimi ve Kısıtları.....	6
3.2. Literatürdeki Temel Çalışmaların Metodolojik Analizi.....	7
3.2.1. CICIDS2017 Veri Seti Üzerine Random Forest Uygulamaları.....	7
3.2.2. UNSW-NB15 ve Hibrit Saldırı Senaryoları.....	7
3.2.3. CSE-CIC-IDS2018 ve Gradyan Artırma Algoritmaları.....	7
3.3. Karşılaştırmalı Literatür Özeti ve Performans Metrikleri.....	7
4. YÖNTEM VE METODOLOJİ.....	8
4.1. Ham Verilerin Analize Hazırlanması ve Standartlaştırma.....	8
4.2. Öznitelik Seçimi ve Boyut İndirgeme Stratejileri.....	9
4.3. Anomali Tespitinde Kullanılan Modelleme Yaklaşımları.....	9
4.4. Model Başarısının Ölçülmesi ve Performans Kriterleri.....	9
5. MODEL BAŞARIMI ÜZERİNE TEKNİK ÖNGÖRÜLER VE TARTIŞMA.....	10
5.1. Performans Metrikleri ve Literatürle Karşılaştırma.....	10
5.2. Veri Kümesindeki Sınıf Dengesizliği ve Model Direnci.....	10
5.3. Algoritmaların Operasyonel Verimliliği.....	10
6. GENEL DEĞERLENDİRME VE GELECEK VİZYONU.....	11
6.1. Çalışmanın Özeti ve Temel Çıkarımlar.....	11
6.2. Akademik ve Pratik Katkıları.....	11
6.3. Genişletme ve Geliştirme Önerileri.....	11
7. KAYNAKLAR.....	12

1. GİRİŞ

Bilgi ve iletişim teknolojilerindeki hızlı ilerleme, ağ altyapılarını modern toplumun ve endüstrinin vazgeçilmez bir unsuru haline getirmiştir. Ancak bu dijitalleşme süreci, ağların maruz kaldığı güvenlik tehditlerinin hem nicelik hem de nitelik bakımından evrilmesine yol açmıştır. Bu bölümde; ağ güvenliğinin güncel durumu, geleneksel savunma yöntemlerinin karşılaştığı teknik zorluklar ve bu çalışmada temel alınan anomali tespiti yaklaşımının gerekliliği üzerinde durulmaktadır. Ayrıca, karmaşık ağ verilerinin analizinde makine öğrenmesi yöntemlerinin neden tercih edildiği ve projenin genel hedefleri akademik bir çerçevede sunulmaktadır.

1.1. Modern Ağ Yapılarında Güvenlik İhtiyacı ve Tehdit Dinamikleri

Günümüzde veri trafiği, nesnelerin interneti (IoT) ve bulut tabanlı servislerin etkisiyle daha önce görülmemiş bir hacme ulaşmıştır. Bu durum, siber saldırganlar için çok daha geniş ve karmaşık bir saldırı yüzeyi oluşturmaktadır. Modern siber tehditler artık yalnızca basit zararlı yazılımlarla sınırlı kalmayıp; devlet destekli operasyonlar, gelişmiş kalıcı tehditler (APT) ve fidye yazılımı ağları gibi yüksek profilli riskleri barındırmaktadır. Dolayısıyla, ağ trafiğinin sürekli ve dinamik bir şekilde denetlenmesi, stratejik bir zorunluluk olarak değerlendirilmektedir.

1.2. Klasik Saldırı Tespit Sistemlerinin Sınırları

Savunma mimarilerinde uzun yıllardır kullanılan imza tabanlı (signature-based) sistemler, bilinen saldırı kalıplarının veri tabanı ile eşleştirilmesi prensibiyle çalışmaktadır. Bu yöntem bilinen tehditlere karşı etkin olsa da, günümüzün hızla değişen saldırı ortamında yetersiz kalmaktadır:

- **Sıfıncı Gün (Zero-day) Riskleri:** Henüz tanımlanmamış ve imzası oluşturulmamış saldırılar bu sistemler tarafından fark edilememektedir.
- **Polimorfik Tehditler:** Saldırganların mevcut saldırı kodlarını yapısal olarak değiştirmesi, statik imza kontrol mekanizmalarının atlatılmasına neden olmaktadır. Bu kısıtlar, savunma stratejilerinde verinin içeriğinden ziyade trafiğin davranışsal özelliklerine odaklanılmasını zorunlu kılmıştır.

1.3. Davranışsal Karakterizasyon ve Anomali Tespiti

Anomali tespiti, ağ trafiğindeki olağan akışı (baseline) modelleyerek bu modelden istatistiksel veya yapısal olarak sapan aktiviteleri tespit etme sürecidir. Bu yaklaşımın temel avantajı, saldırının kimliği bilinmese dahi, ağın doğal işleyişindeki bozulmaların bir güvenlik ihlali olarak işaretlenebilmesidir. Örneğin, belirli bir zaman diliminde paket boyutlarındaki ani değişimler veya bağlantı frekanslarındaki sapmalar, proaktif bir savunma hattı oluşturulmasına imkan tanımaktadır.

1.4. Makine Öğrenmesi Yöntemlerinin Kullanım Motivasyonu

Ağ trafiği, saniyede milyonlarca kayıt üreten yüksek boyutlu bir veri yapısına sahiptir. Makine öğrenmesi algoritmaları, bu devasa veri yığınları içerisindeki gizli korelasyonları ve doğrusal olmayan ilişkileri öğrenme kapasitesine sahiptir.

Bu çalışmada makine öğrenmesinin tercih edilme nedenleri şunlardır:

- **Hızlı Veri Analizi:** Milyonlarca satırlık modern veri setlerinde modellerin gerçek zamanlıya yakın analiz gerçekleştirebilmesi.
- **Öznitelik Mühendisliği:** Veri seti içerisindeki onlarca parametreden saldırıyı en iyi niteleyenlerin (akış süresi, paket boyutu vb.) matematiksel yöntemlerle belirlenebilmesi.
- **Sürekli Öğrenme:** Modellerin, değişen trafik alışkanlıklarına göre yeniden eğitilerek güncelliğini koruyabilmesi.

1.5. Çalışmanın Kapsamı ve Genel Hedefler

Bu proje kapsamında, literatürde standart kabul edilen veri setleri üzerinden DDoS, Port Tarama ve Brute Force gibi anomalileri yüksek doğrulukla sınıflandırabilen bir modelin geliştirilmesi hedeflenmektedir. Çalışma; verilerin ön işleme adımlarından modelin performans analizine kadar olan tüm süreci akademik standartlarda ele alarak, ağ güvenliğinde hata payını minimize etmeyi amaçlamaktadır.

2. AĞ GÜVENLİĞİ VE SALDIRI MEKANİZMALARININ TEKNİK ANALİZİ

Geliştirilecek olan saldırı tespit modelinin başarısı, ağ protokollerinin ve saldırı yöntemlerinin teknik altyapısının doğru bir şekilde analiz edilmesine bağlıdır. Bu bölümde, ağ trafiğinin katmanlı yapısı incelenerek saldırıların bu katmanlardaki teknik yansımaları ele alınmaktadır. Ayrıca, anomali tespiti çalışmalarında kullanılan veri setlerinin genel yapısal özellikleri ve bu verilerden elde edilen özniteliklerin teknik anlamları üzerinde durulmaktadır.

2.1. Protokol Katmanları ve Güvenlik Açıkları

Saldırıların ağ üzerindeki etkisini belirlemek için OSI (Open Systems Interconnection) modeli temel alınmaktadır. Proje kapsamında incelenen anomaliler genellikle şu katmanları hedef almaktadır:

- **Ağ Katmanı (Katman 3):** IP protokolü üzerinden gerçekleştirilen ve kaynak/hedef manipülasyonuna dayalı saldırılar bu katmanda izlenir. Veri setlerindeki IP bazlı öznitelikler bu katman analizinde kritik rol oynar.

- **Taşıma Katmanı (Katman 4):** TCP ve UDP protokollerinin davranışsal anomalileri burada gerçekleşir. Akış bazlı (flow-based) sistemler, özellikle paketlerin el sıkışma süreçlerini ve bayrak (flag) kullanımlarını bu katmanda denetlemektedir.
- **Uygulama Katmanı (Katman 7):** Doğrudan kullanıcı servislerini hedef alan saldırılar bu katmanda yoğunlaşır. Brute Force saldırıları bu katmandaki protokol mekanizmalarını istismar ederek gerçekleştirilir.

2.2. Temel Saldırı Türlerinin İşleyiş Mantığı

Ağ anomalileri, protokollerin çalışma prensiplerindeki zafiyetleri kullanarak hedef sistemleri etkisiz hale getirmeyi amaçlar. Çalışmada odaklanılan ana saldırı türlerinin teknik anatomisi şöyledir:

2.2.1. DoS ve DDoS Ataklarında TCP İstismarı

En yaygın anomalilerden biri olan SYN Flood, TCP üçlü el sıkışma (3-way handshake) sürecini suiistimal eder.

1. Saldırgan sistem hedefe yoğun SYN paketleri gönderir.
2. Hedef sistem SYN-ACK cevabı döner ve bağlantıyı "yarım açık" durumda tutarak kaynak ayırır.
3. Saldırgan taraf son ACK paketini göndermeyerek sunucu belleğini tüketir ve sistemi servis dışı bırakır.

Bu durum veri setlerinde, saniyedeki paket sayısı ve ileri yönlü akış frekansındaki orantısız artışlarla kendini göstermektedir.

2.2.2. Port Tarama ve Keşif Faaliyetleri

Saldırganların hedefteki açık kapıları ve servisleri belirlemek için yürüttüğü süreçtir. Kısa bir zaman aralığında çok sayıda farklı hedef porta yönelik yapılan bağlantı istekleri ile ayırt edilir. Teknik olarak, paketler arası varış süresinin (IAT) düşüklüğü ve hedef port çeşitliliği bu saldırının tespitinde en güçlü göstergelerdir.

2.2.3. Brute Force ve Periyodik Akışlar

SSH veya FTP gibi servisleri ele geçirmek için yapılan sistematik parola denemeleridir. Ağ trafiğinde "tekrar eden, kısa süreli ve benzer paket boyutuna sahip" bir örüntü oluşturur. Makine öğrenmesi modelleri, bu periyodikliği ve başarısız bağlantı sıklığını yakalayarak tespiti gerçekleştirir.

2.3. Saldırı Tespit Veri Setlerinin Genel Yapısı

Modern veri setleri (CSE-CIC-IDS2018, CICIDS2017 vb.), ham ağ paketlerinin (PCAP) işlenerek sayısal özniteliklere dönüştürülmesiyle elde edilmektedir. Bu verilerin temsil ettiği temel öznitelik grupları aşağıda özetlenmiştir:

Öznitelik Kategorisi	Teknik İçerik	Önem Derecesi
Zamanlama Analizi	Flow Duration, Flow IAT, Timestamp	Yüksek
Hacimsel Metrikler	Paket sayıları, Ortalama paket boyutları	Orta
Durum Kontrolü	SYN, RST, ACK Bayrak sayıları	Yüksek

Bu özniteliklerin doğru bir şekilde temizlenmesi ve normalizasyonu, geliştirilecek olan sınıflandırma modelinin başarısını belirleyen en temel unsurlardır.

3. BİLİMSEL YAZIN TARAMASI

Ağ anomali tespiti alanı, siber tehditlerin evrimiyle paralel olarak sürekli gelişen dinamik bir araştırma sahasıdır. Bu bölümde, literatürde standart kabul edilen veri setlerinin tarihsel gelişimi ve bu veriler üzerinde gerçekleştirilen öncü çalışmalar akademik bir perspektifle incelenmektedir. Yapılan incelemeler; kullanılan algoritmaların başarımı, veri ön işleme tekniklerinin etkisi ve farklı saldırı türlerine karşı modellerin sergilediği direnç noktalarına odaklanmaktadır.

3.1. Ağ Güvenliği Veri Setlerinin Tarihsel Gelişimi ve Kısıtları

Saldırı tespit sistemlerinin başarımını ölçmek için kullanılan veri setleri, yıllar içerisinde daha gerçekçi ve karmaşık hale gelmiştir. İlk dönem çalışmalarında yaygın olarak kullanılan KDD Cup 99 ve NSL-KDD gibi setler, günümüzün modern ağ trafiğini temsil etmekte yetersiz kalmaktadır. Bu yetersizliğin temel nedenleri arasında; trafik hacminin düşüklüğü, modern saldırı türlerinin (örneğin güncel DDoS varyasyonları) eksikliği ve verilerin yapay bir ortamda çok fazla tekrarlanması yer almaktadır.

Bu kısıtları aşmak amacıyla geliştirilen UNSW-NB15 veri seti, hibrit saldırı senaryolarını ve modern ağ protokollerini içermesiyle literatürde önemli bir dönüm noktası oluşturmuştur. Son yıllarda ise Sharafaldin ve arkadaşları tarafından sunulan CICIDS2017 ve ardından Amazon AWS ortamında simüle edilen CSE-CIC-IDS2018 veri setleri, milyonlarca kayıt ve 80 farklı öznitelik ile araştırmacılara en güncel ve kapsamlı test ortamını sunmaktadır.

3.2. Literatürdeki Temel Çalışmaların Metodolojik Analizi

Literatür taraması kapsamında incelenen çalışmalar, anomali tespitinde farklı makine öğrenmesi yaklaşımlarının avantaj ve dezavantajlarını ortaya koymaktadır. Aşağıda, projenin metodolojisine yön veren temel araştırmalar detaylandırılmaktadır:

3.2.1. CICIDS2017 Veri Seti Üzerine Random Forest Uygulamaları

Sharafaldin vd. (2017/2018) tarafından gerçekleştirilen çalışmada, modern saldırı türlerini içeren CICIDS2017 veri seti üzerinde çeşitli sınıflandırma algoritmaları test edilmiştir. Araştırmada özellikle öznitelik ölçeklendirme (Feature Scaling) adımlarının model başarısı üzerindeki etkisi vurgulanmıştır.

- Yapılan deneylerde, Random Forest algoritmasının ağ trafiği üzerindeki karmaşık desenleri öğrenmede oldukça başarılı olduğu gözlemlenmiştir.
- Elde edilen sonuçlar; %90 doğruluk (Accuracy) ve %97 F1-skoru ile literatürde önemli bir referans noktası oluşturmıştır.
- Bu çalışma, ağ trafiğindeki özniteliklerin (özellikle bayrak sayıları ve paket boyutları) saldırı tespitindeki ayırt edici gücünü kanıtlar niteliktedir.

3.2.2. UNSW-NB15 ve Hibrit Saldırı Senaryoları

Moustafa ve Slay (2015) tarafından yürütülen araştırmada, UNSW-NB15 veri seti kullanılarak karmaşık saldırıların tespiti üzerine odaklanılmıştır.

- Bu çalışmada, normalizasyon tekniklerinin verideki gürültüyü azaltmada kritik bir rol oynadığı belirtilmiştir.
- Uygulanan SVM ve Naive Bayes gibi geleneksel yöntemlerin, bazı karmaşık saldırı türlerinde yüksek yanlış alarm (False Positive) oranlarına sahip olduğu saptanmıştır.
- Araştırma, anomali tespitinde sadece doğruluk oranına değil, aynı zamanda modelin genellenebilirliğine de odaklanması gerektiğini göstermiştir.

3.2.3. CSE-CIC-IDS2018 ve Gradyan Artırma Algoritmaları

İman vd. (2018) tarafından yapılan çalışmada, en güncel veri setlerinden biri olan CSE-CIC-IDS2018 üzerinde XGBoost algoritması kullanılmıştır.

- Büyük veri setlerinde sınıf dengesizliği (imbalance) sorununu çözmek amacıyla SMOTE gibi yöntemlerin etkinliği tartışılmıştır.
- XGBoost algoritmasının, paralel işlem kapasitesi ve büyük veri hacimlerini işleme hızı sayesinde CSE-CIC-IDS2018 gibi devasa setlerde oldukça dengeli bir başarı sergilediği rapor edilmiştir.

3.3. Karşılaştırmalı Literatür Özeti ve Performans Metrikleri

İncelenen çalışmaların metodolojik yapıları ve elde edilen sonuçlar aşağıdaki tabloda karşılaştırmalı olarak sunulmaktadır:

Yazar	Veri Seti	Önişleme Tekniği	Kullanılan Yöntem	Performans (Acc/F1)
Sharafaldin vd.	CICIDS2017	Feature Scaling	Random Forest	%90 / %97
Moustafa vd.	UNSW-NB15	Normalization	SVM/NB	Belirsiz/Değişken
Iman vd.	CSE-CIC-IDS2018	SMOTE	XGBoost	Dengeli Başarı

4. YÖNTEM VE METODOLOJİ

Ağ anomali tespit sisteminin geliştirilme süreci; ham verilerin toplanması, anlamlı özniteliklerin seçilmesi, modellerin eğitilmesi ve elde edilen sonuçların doğrulanması aşamalarından oluşan sistematik bir döngüyü kapsamaktadır. Bu bölümde, çalışmanın uygulama aşamasında takip edilecek teknik yol haritası detaylandırılmaktadır. Ham verilerin model girişine uygun hale getirilmesi için uygulanacak önişleme teknikleri, öznitelik mühendisliği stratejileri ve kullanılacak algoritmaların matematiksel dayanakları bu başlık altında ele alınmaktadır.

4.1. Ham Verilerin Analize Hazırlanması ve Standartlaştırma

Ağ trafiğinden elde edilen veri setleri, yapıları gereği gürültülü veriler, eksik kayıtlar veya modelin işleyemeyeceği formatta öznitelikler içerebilmektedir. Modelin başarısını doğrudan etkileyen bu durumun önüne geçmek amacıyla şu adımların izlenmesi planlanmaktadır:

- **Veri Temizleme:** Veri setindeki eksik (null) veya matematiksel olarak işlenemeyen sonsuz (inf) değerlerin tespiti ve bu kayıtların veri bütünlüğünü bozmayacak şekilde temizlenmesi.
- **Kategorik Veri Dönüşümü:** Protokol türleri (TCP, UDP, ICMP) gibi sözel ifadelerin, makine öğrenmesi algoritmaları tarafından işlenebilmesi için "Label Encoding" veya "One-Hot Encoding" yöntemleriyle sayısal değerlere dönüştürülmesi hedeflenmektedir.

- **Öznitelik Ölçeklendirme:** Farklı sayısal aralıklara sahip özniteliklerin (örneğin akış süresi ve paket boyutu), modelin belirli bir parametreye aşırı odaklanmasını önlemek amacıyla "Normalization" veya "Standardization" teknikleriyle belirli bir skalaya (genellikle 0-1 aralığı) çekilmesi öngörülmektedir.

4.2. Öznitelik Seçimi ve Boyut İndirgeme Stratejileri

Modern ağ güvenliği veri setlerinde yer alan onlarca farklı özneliğin tamamı, her saldırı türü için aynı derecede ayırt edici olmayabilir. Gereksiz veya birbirini tekrarlayan (redundant) özelliklerin modelden çıkarılması, hem eğitim süresini kısaltmakta hem de modelin karmaşıklığını azaltarak aşırı öğrenme (overfitting) riskini minimize etmektedir.

- **Korelasyon Analizi:** Öznitelikler arasındaki istatistiksel ilişkinin incelenerek, hedef değişken (saldırı türü) ile en yüksek korelasyona sahip parametrelerin belirlenmesi hedeflenmektedir.
- **Bilgi Kazancı (Information Gain):** Hangi özneliğin, trafiğin "normal" veya "anomalı" olarak sınıflandırılmasında daha fazla bilgi sağladığının matematiksel olarak hesaplanması ve en etkili özniteliklerin seçilmesi planlanmaktadır.

4.3. Anomali Tespitinde Kullanılan Modelleme Yaklaşımları

Çalışmada, literatürde ağ trafiği analizi ve sınıflandırma problemlerinde yüksek performans sergilediği kanıtlanmış olan Ensemble Learning yöntemlerine odaklanılmaktadır.

- **Random Forest:** Çok sayıda karar ağacının bir araya gelerek oylama mekanizmasıyla sonuç ürettiği bu algoritma, ağ trafiğindeki gürültülü verilere karşı yüksek direnç göstermesi nedeniyle tercih edilmektedir.
- **Ekstrem Gradyan Artırma (XGBoost):** Hataları minimize ederek ilerleyen gradyan artırma tekniği, özellikle büyük veri setlerinde (örneğin CSE-CIC-IDS2018) işlem hızı ve bellek verimliliği açısından önemli avantajlar sunmaktadır.

4.4. Model Başarısının Ölçülmesi ve Performans Kriterleri

Geliştirilen modellerin başarısı, yalnızca genel doğruluk oranı (Accuracy) ile değil, siber güvenlikte kritik öneme sahip olan ve yanlış alarmları minimize eden farklı metriklerle değerlendirilecektir.

- **Hata Matrisi (Confusion Matrix):** Modelin gerçek saldırıları ne kadar doğru bildiğini ve normal trafiği ne kadar sıklıkla yanlışlıkla saldırı olarak işaretlediğini (False Positive) gösteren temel araç olarak kullanılacaktır.
- **Hassasiyet (Precision) ve Duyarlılık (Recall):** Modelin saldırı tespitindeki kesinliğini ve mevcut saldırıların ne kadarını yakalayabildiğini ölçmek amacıyla analiz edilecektir.
- **F1-Skoru:** Hassasiyet ve duyarlılık değerlerinin harmonik ortalaması alınarak, modelin dengeli başarısı raporlanacaktır.

5. MODEL BAŞARIMI ÜZERİNE TEKNİK ÖNGÖRÜLER VE TARTIŞMA

Bu bölümde, metodoloji kısmında belirtilen adımların uygulanması sonucunda elde edilmesi beklenen veriler ve bu verilerin literatürdeki çalışmalarla olan tutarlılığı ele alınmaktadır. Yapılan analizler; modelin sınıflandırma kabiliyeti, veri setindeki dengesizliklerin performansa etkisi ve algoritmaların karakteristik farkları üzerine odaklanmaktadır.

5.1. Performans Metrikleri ve Literatürle Karşılaştırma

Uygulama aşamasında kullanılan Random Forest ve XGBoost modellerinden, literatürdeki benzer çalışmalarla paralel olarak %90 ve üzeri bir genel doğruluk (Accuracy) oranı elde edilmesi öngörülmektedir. Ancak ağ güvenliği projelerinde doğruluk oranından ziyade, özellikle saldırıların ne kadarının yakalandığını gösteren Duyarlılık (Recall) ve yanlış alarmların oranını belirleyen Hassasiyet (Precision) metrikleri kritik önem taşımaktadır.

- **F1-Skoru Beklentisi:** Literatürde %97 seviyelerine ulaşan F1-skorları, modellerin karmaşık saldırı desenlerini (özellikle DDoS ve Port Tarama) başarıyla ayırt edebildiğini göstermektedir.
- **Yanlış Alarm Analizi:** Normal ağ trafiğinin yanlışlıkla saldırı olarak işaretlenmesi (False Positive), ağ yöneticileri için iş yükü oluşturmaktadır. Bu çalışmada uygulanacak öz nitelik seçimi yöntemleriyle bu oranın minimize edilmesi hedeflenmektedir.

5.2. Veri Kümesindeki Sınıf Dengesizliği ve Model Direnci

Ağ trafiği veri setlerinde normal trafik kayıtları, saldırı kayıtlarına oranla çok daha baskındır. Bu durum, modelin "çoğunluk sınıfına" eğilim göstermesine (bias) neden olabilmektedir.

- **Dengeleme Stratejileri:** SMOTE gibi sentetik veri artırma tekniklerinin veya algoritmaların sınıf ağırlıklandırma parametrelerinin, modelin nadir görülen saldırı türlerini (örneğin Brute Force) tanımasındaki başarıyı artıracağı düşünülmektedir.
- **Öznitelik Etkisi:** Paket boyutlarındaki standart sapmalar ve bayrak sayıları gibi ayırt edici özelliklerin, sınıf dengesizliğine rağmen modelin karar verme sürecini güçlendirdiği öngörülmektedir.

5.3. Algoritmaların Operasyonel Verimliliği

Proje kapsamında test edilen iki temel algoritmanın farklı güçlü yönleri mevcuttur. Random Forest algoritmasının, özellikle gürültülü verilerde ve eksik öz nitelik durumlarında kararlı bir yapı sergilemesi beklenmektedir. Diğer yandan XGBoost algoritmasının, büyük veri hacimlerini (örneğin CSE-CIC-IDS2018) işleme hızı ve bellek yönetimi açısından daha

verimli sonuçlar üreteceği, dolayısıyla gerçek zamanlı sistemlere entegrasyon için daha uygun bir aday olduğu değerlendirilmektedir.

6. GENEL DEĞERLENDİRME VE GELECEK VİZYONU

Bu çalışmada, modern ağ yapılarında siber güvenliğin en kritik unsurlarından biri olan anomali tespiti süreci, makine öğrenmesi yaklaşımlarıyla kapsamlı bir şekilde ele alınmıştır. Yapılan araştırmalar ve kurgulanan metodoloji, veri odaklı savunma mekanizmalarının ağ güvenliğindeki stratejik yerini doğrular niteliktedir.

6.1. Çalışmanın Özeti ve Temel Çıkarımlar

Proje süresince, imza tabanlı sistemlerin yetersiz kaldığı alanlarda davranışsal analizin sunduğu proaktif çözümler incelenmiştir. Literatürde kabul görmüş modern veri setleri üzerinden yapılan teknik analizler; doğru öznitelik seçimi ve uygun algoritma optimizasyonu ile ağ anomalilerinin yüksek doğrulukla tespit edilebileceğini göstermiştir. Özellikle TCP protokol mekanizmalarını hedef alan saldırıların, akış bazlı istatistiklerle net bir şekilde karakterize edilebildiği saptanmıştır.

6.2. Akademik ve Pratik Katkıları

Bu rapor, ham bir ağ verisinin akademik standartlarda nasıl işlenmesi gerektiğini ve modelleme süreçlerindeki kritik başarı faktörlerini ortaya koymaktadır. Geliştirilen yaklaşım; siber güvenlik uzmanları için yanlış alarmları azaltan, araştırmacılar için ise farklı algoritmaların büyük veri setleri üzerindeki performansını kıyaslayan metodolojik bir rehber niteliği taşımaktadır.

6.3. Genişletme ve Geliştirme Önerileri

Saldırı tespit sistemlerinin verimliliğini artırmak amacıyla gelecek çalışmalarda şu odak noktaları önerilmektedir:

- **Derin Öğrenme Entegrasyonu:** Özellikle zaman serisi verilerinde başarılı olan Uzun-Kısa Süreli Bellek (LSTM) ağlarının, saldırıların zamansal değişimlerini yakalamada kullanılması.
- **Gerçek Zamanlı Uygulama:** Geliştirilen modellerin bir SDN (Yazılım Tanımlı Ağ) veya sınır bilişim (edge computing) mimarisine entegre edilerek canlı trafik üzerinde test edilmesi.
- **Hibrit Veri Setleri:** Farklı veri setlerinin birleştirilerek modelin genellebilirliğinin ve farklı ağ topolojilerine adaptasyonunun artırılması.

7. KAYNAKLAR

Babalık, F. (2016). Mühendisler için ergonomi -İşbilim. Bursa: Dora Yayıncılık.

Bauer, J., Leydesdorff, L. ve Bornmann, L. (basım aşamasında). Highly-cited papers in Library and Information Science (LIS): Authors, institutions, and network structures. Journal of the Association for Information Science and Technology. Erişim adresi: <http://arxiv.org/ftp/arxiv/papers/1504/1504.0257> 6.pdf.

Eskişehir Osmangazi Üniversitesi Mühendislik ve Mimarlık Fakültesi Dergisi Yazım Kuralları ve Makale Şablonu. (2023). Erişim adresi: <https://dergipark.org.tr/tr/pub/ogummf>.

Iman, M. S., Ahmad, Z. ve Habib, M. A. (2018). Evaluation of CSE-CIC-IDS2018 dataset for network intrusion detection systems using machine learning. International Journal of Advanced Computer Science and Applications, 9(12), 154-162.

Moustafa, N. ve Slay, J. (2015). UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set). 2015 Military Communications and Information Systems Conference (MilCIS), Canberra, ACT, Australia, 1-6. doi: 10.1109/MilCIS.2015.7348942.

Sharafaldin, I., Lashkari, A. H. ve Ghorbani, A. A. (2018). Toward generating a new dataset for network intrusion detection and intrusion prevention systems. Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP 2018), Portugal, 108-116.

Zhang, L. ve Liu, Q. (2009). Research on network intrusion detection based on machine learning. 2009 International Conference on Information Engineering and Computer Science, Wuhan, 1-4.