

T.C.
ESKİŐEHİR OSMANGAZİ ÜNİVERSİTESİ MÜHENDİSLİK
MİMARLIK FAKÜLTESİ



MAKİNE ÖĞRENMESİ
152118633

2025-2026 BAHAR YARIYILI

Ağ Anomali Tespiti

PROJE RAPORU - 2

Grup No: 6

Grup Üyeleri

Çağrı Elagöz - 152120211097

Yusuf Özgöçmen - 152120221093

Özet.....	3
1. Giriş.....	3
1.1. Ağ Güvenliğinde Güncel Tehdit Manzarası ve Anomali Tespitinin Önemi.....	3
1.2. Çalışmanın Motivasyonu ve Katkısı.....	4
2. Genişletilmiş Literatür Taraması.....	4
2.1. Ağ Anomali Tespitinde Öncü Makalelerin ve Metodolojilerin İncelenmesi.....	4
2.2. Modern NIDS Veri Setleri Üzerine Yapılan Çalışmalar.....	5
2.3. Sınıf Dengesizliği (Class Imbalance) ve Çözüm Stratejileri Literatürü.....	6
3. Materyal ve Yöntem: Uygulamaya Başlangıç.....	7
3.1. CSE-CIC-IDS2018 Veri Setinin Seçim Rasyonalitesi ve Karakteristikleri.....	7
3.2. Veri Ön işleme Boru Hattı (Data Preprocessing Pipeline).....	7
3.3. Boyut İndirgeme ve Öznitelik Seçimi (Feature Selection) Stratejisi.....	8
3.4. SMOTE ile Sentetik Veri Artırma ve Sınıf Dengeleme.....	8
4. Sistem Mimarisi ve Algoritmik Çerçeve.....	9
4.1. Bagging Yaklaşımı: Rastgele Orman (Random Forest).....	9
4.2. Boosting Yaklaşımı: Ekstrem Gradyan Artırma (XGBoost).....	9
5. Deneysel Kurulum ve Değerlendirme Metrikleri.....	11
5.1. Performans Ölçütleri (Doğruluk, Duyarlılık, Kesinlik ve F1-Skoru).....	11
5.2. Beklenen Operasyonel Çıktılar ve Doğruluk Yanılgısının Aşılması.....	11
6. Sonuç.....	11
7. Gelecek Planları ve Araştırma Yönelimleri.....	12
7.1. Derin Öğrenme ve Zamansal (Temporal) Analiz Entegrasyonu.....	12
7.2. Yazılım Tanımlı Ağlar (SDN) ve Sınır Bilişim (Edge Computing).....	12
7.3. Açıklanabilir Yapay Zeka (XAI) ile Karar Şeffaflığı.....	12
7.4. Çekişmeli Makine Öğrenmesi ve Model Dayanıklılığı.....	12
8. Kaynakça (References).....	13
8.1. Alıntılanan Çalışmalar.....	14

Özet

Günümüzün hızla genişleyen dijital ağ altyapılarında, sıfırinci gün (zero-day) ve polimorfik siber saldırıları tespit etmek geleneksel imza tabanlı güvenlik sistemleri için imkansız hale gelmiştir. Bu çalışma, modern ağ trafiklerindeki anomali örüntülerini otonom olarak yakalayabilmek amacıyla makine öğrenmesi ve özellikle topluluk öğrenme (ensemble learning) algoritmalarının etkinliğini araştırmaktadır. Projemiz kapsamında, Amazon AWS ortamında simüle edilen ve güncel saldırı vektörlerini barındıran devasa boyutlu CSE-CIC-IDS2018 veri seti kullanılmıştır. Sınıf dengesizliği (class imbalance) ve yüksek boyutsallık gibi temel veri bilimi zorluklarını aşmak adına, literatürdeki SMOTE, alt örnekleme (undersampling) ve gelişmiş öznitelik seçimi (feature selection) teknikleri derinlemesine incelenmiştir. Literatür bulguları, Random Forest (Rastgele Orman) ve XGBoost (Ekstrem Gradyan Artırma) algoritmalarının yüksek doğruluk (%99+) ve F1-Skoru sağlayarak Ağ Anomali Tespit Sistemlerinde (NIDS) endüstri standardı haline geldiğini göstermektedir. Bu rapor, geliştirilecek olan NIDS prototipinin teorik altyapısını, veri ön işleme metodolojisini, sınıflandırma mimarilerini ve gelecekteki araştırma yönelimlerini kapsamlı bir şekilde sunmaktadır.

1. Giriş

1.1. Ağ Güvenliğinde Güncel Tehdit Manzarası ve Anomali Tespitinin Önemi

Nesnelerin İnterneti (IoT), bulut bilişim, uç bilişim ve sanallaştırma teknolojilerinin küresel çapta benimsenmesi, ağ trafiğinde eşi benzeri görülmemiş bir veri patlamasına yol açmıştır. Genişleyen bu devasa saldırı yüzeyi, geleneksel siber güvenlik paradigmalarının çökmesine neden olmuştur. Güvenlik duvarları ve klasik İzinsiz Giriş Tespit Sistemleri (IDS) genellikle imza tabanlı (signature-based) çalışmakta olup, yalnızca veri tabanlarında önceden tanımlanmış şablonlara uyan tehditleri algılayabilmektedir.¹ Ancak modern siber tehditler; yapısı sürekli değişen polimorfik zararlı yazılımlar, daha önce hiç karşılaşılmamış sıfırinci gün (zero-day) açıkları ve normal kullanıcı trafiğinin içine gizlenen sinsi keşif faaliyetleri olarak evrilmiştir.¹

Bu bağlamda, siber savunma hattı "davranışsal karakterizasyon" ilkesine, yani makine öğrenmesi tabanlı anomali tespit sistemlerine doğru kaymıştır. Makine öğrenmesi algoritmaları, ağın olağan akışını (baseline) istatistiksel olarak öğrenmekte ve bir saldırının imzası bilinmese dahi, paket iletim hızı, bağlantı frekansı veya bayrak (flag) dağılımındaki matematiksel sapmaları "anomali" olarak sınıflandırabilmektedir.¹ Davranışsal yaklaşımlar, ağın normal işleyişini modellediği için sıfırinci gün risklerine karşı en büyük savunma mekanizmasını oluşturmaktadır.

1.2. Çalışmanın Motivasyonu ve Katkısı

Ağ anomali tespitinde makine öğrenmesi algoritmalarının başarısı doğrudan veri setlerinin temsil kabiliyetine ve kalitesine bağlıdır. Bu projenin temel motivasyonu; eski ve laboratuvar ortamına sıkışmış KDD99 gibi veri setlerini terk ederek, bulut tabanlı modern tehditleri (DDoS varyantları, Port Tarama, Brute Force) barındıran CSE-CIC-IDS2018 veri seti üzerinde sağlam bir sınıflandırma mimarisi inşa etmektir.¹

Projemizin literatüre ve uygulamaya sunacağı temel katkı, yalnızca yüksek bir "Doğruluk (Accuracy)" oranına ulaşmak değil; NIDS alanındaki en büyük yanılgı olan sınıf dengesizliğinden kaynaklı model körlüğünü (bias) bertaraf etmektir. Geliştireceğimiz model, ağ yöneticilerini sahte alarmlarla yormamak için Hassasiyet (Precision) ve gerçek tehditleri kaçırmamak için Duyarlılık (Recall) metriklerini dengeleyen F1-Skorunu maksimize etmeye odaklanmaktadır.¹

2. Genişletilmiş Literatür Taraması

Makine öğrenmesi tabanlı NIDS mimarilerinin geliştirilmesinde referans alınacak en uygun yaklaşımları belirlemek adına, son yıllarda IEEE, Elsevier ve MDPI gibi saygın akademik veri tabanlarında yayımlanan ampirik çalışmalar incelenmiştir. Özellikle projemizde kullanılacak olan algoritmaları ve veri setini temel alan 4 kritik makale, metodolojimize yön vermesi açısından aşağıda detaylıca analiz edilmiştir.

2.1. Ağ Anomali Tespitinde Öncü Makalelerin ve Metodolojilerin İncelenmesi

Makale 1: Coşar vd. (2024) - CSE-CIC-IDS2018 Üzerinde Makine Öğrenmesi Yöntemleri ile İzinsiz Giriş Tespiti Coşar, Arısoy ve Ulutaş tarafından yürütülen bu araştırma, doğrudan projemizin merkezinde yer alan CSE-CIC-IDS2018 veri seti üzerine inşa edilmiştir.² Yazarlar, veri setinin içerdiği HTTPS, HTTP, SSH, FTP gibi protokoller üzerinden gelen saldırıları (özellikle Brute Force gibi) sınıflandırmak için altı farklı makine öğrenmesi modelini kıyaslamıştır.² Çalışmanın projemiz için en önemli çıktısı; XGBoost, LightGBM ve CatBoost gibi "Boosting" tabanlı algoritmaların 0.98 doğruluk, 0.98 F1-Skoru ve mükemmele yakın 1.00 AUC skoru ile diğer tüm algoritmaları geride bırakmış olmasıdır.² Bu sonuçlar, projemizde XGBoost algoritmasına neden ağırlık vereceğimizin en güçlü akademik kanıtıdır.

Makale 2: Lawal, Makinde vd. (2025) - CSE-CIC-IDS2018 Veri Seti Kullanılarak İzinsiz Giriş Tespiti İçin Karşılaştırmalı Analiz Bu güncel çalışma, milyonlarca satırlık devasa veri setlerinin neden olduğu "Sınıf Dengesizliği" (Class Imbalance) problemine odaklanmaktadır.³ Lawal ve ekibi, ağ trafiğindeki aşırı normal veri yığılmasını çözmek için "Alt Örnekleme" (Undersampling) tekniklerini kullanmış ve modeli bu dengeli veriyle eğitmiştir.³ Yapılan testlerde; Random Forest, SVM, KNN ve Lojistik Regresyon arasından yine XGBoost öne çıkmış; %96 doğruluk, %94

kesinlik (precision) ve %98 duyarlılık (recall) oranlarına ulaşmıştır.³ Yüksek duyarlılık oranı, XGBoost'un gerçek tehditleri kaçırmama (False Negative oranını düşürme) konusundaki üstünlüğünü kanıtlamaktadır.

Makale 3: Castro vd. (2026) - Ağ Günlüklerinde İzinsiz Giriş Tespiti İçin Gözetimli ve Gözetimsiz Öğrenmenin Karşılaştırmalı Analizi Castro ve arkadaşlarının "Computation" dergisinde yayımlanan kapsamlı analizi, Random Forest (Bagging) ile XGBoost (Boosting) arasındaki operasyonel farkı gözler önüne sermektedir.⁴ Çalışma, Random Forest'in %99.96 gibi olağanüstü bir doğruluk oranına ulaşmasına rağmen, 48 gerçek ve kritik tehdidin 8'ini kaçırdığını saptamıştır.⁴ Buna karşın XGBoost, %99.98 genel doğrulukla beraber 48 kritik tehdidin 46'sını yakalamayı başararak Tehdit Görünürlüğünü (Threat Visibility) ciddi oranda artırmıştır.⁴ Siber güvenlikte tek bir kaçırılan tehdidin bile felakete yol açabileceği düşünüldüğünde, bu %12.5'lik Duyarlılık (Recall) artışı, Boosting algoritmalarının siber güvenlikteki pratik değerini kanıtlamaktadır.⁴

Makale 4: Rafrastara vd. (2025) - Dağıtık Hizmet Aksatma Saldırısı (DDoS) Tespiti İçin Ağaç Tabanlı Topluluk Algoritmaları ve Özellik Seçimi NIDS sistemlerinin en büyük sorunu olan işlem yükünü azaltmayı hedefleyen bu çalışma, "Geliştirilmiş Gini İndeksi" adı verilen bir özellik seçimi (feature selection) yöntemi önermiştir.⁵ UNSW-NB15 veri setinde uygulanan bu özellik seçimi sayesinde, XGBoost algoritması gereksiz özelliklerden arındırılmış bir girdiyle eğitilmiş ve %97.30 oranında doğruluk, duyarlılık ve kesinlik elde etmiştir.⁵ Bu makale, projemizin "Boyut İndirgeme" (Bölüm 3.3) aşamasında neden Bilgi Kazancı (Information Gain) ve benzeri istatistiksel filtreleme ihtiyaç duyduğumuzu doğrulamaktadır.

2.2. Modern NIDS Veri Setleri Üzerine Yapılan Çalışmalar

Güncel araştırmalar genellikle üç modern veri seti etrafında şekillenmektedir:

1. **UNSW-NB15:** Hibrit saldırı senaryolarını barındıran bu veri seti, KDD99'a kıyasla daha homojen bir örüntü dağılımı sunmaktadır.
2. **CICIDS2017:** B-Profile adı verilen ajanlarla fiziksel bir ağ üzerinde üretilmiştir. Soumik (2024), bu veri setinde Sentetik Azınlık Aşırı Örnekleme Tekniği (SMOTE) ve Min-Max ölçeklendirme uygulayarak Random Forest ile %99.90 doğruluk ve %97.41 F1-Skoru elde etmiştir.⁶
3. **CSE-CIC-IDS2018:** Amazon AWS üzerinde devasa bir bulut ağını simüle eden ve 16.2 milyondan fazla kayıt içeren bu veri seti, anomali tespiti için literatürdeki en büyük ve "altın standart" test ortamıdır.¹ İçerisinde modern LOIC/HOIC DDoS, Port Tarama ve çok çeşitli Brute Force (Web, XSS, FTP, SSH) saldırıları bulunmaktadır.² Projemizde, devasa boyutu ve sunduğu yüksek donanım sınaması kapasitesi sebebiyle **CSE-CIC-IDS2018** veri seti tercih edilmiştir.¹

Tablo 1: NIDS Veri Setlerinin Karşılaştırmalı Akademik Profili

Veri Seti	Çıkış Yılı	Veri Hacmi	Temel Saldırı Sınıfları	Öne Çıkan Özelliği	Literatürdeki Yeri
UNSW-NB15	2015	~2.5 Milyon	Fuzzers, DoS, Exploits, Reconnaissance	Hibrit ve modern özellik seti	KDD99'un ilk güçlü modern alternatifi
CICIDS2017	2017	~2.8 Milyon	DDoS, Brute Force, Web Attacks, Infiltration	Gerçekçi B-Profile ajan mimarisi	Ağ iletişimde standart referans
CSE-CIC-IDS 2018	2018	16.2+ Milyon	Genişletilmiş DDoS, Botnet, Web Brute Force	Devasa boyut ve AWS Cloud simülasyonu	Big Data (Büyük Veri) kapasitesi ölçümü

2.3. Sınıf Dengesizliği (Class Imbalance) ve Çözüm Stratejileri

Literatürü

CSE-CIC-IDS2018 veri seti, gerçek dünya ağlarını çok iyi simüle etmesinin bir sonucu olarak aşırı bir sınıf dengesizliğine sahiptir. Öğrenme algoritmaları sadece çoğunluk sınıfına bakarak (örneğin sürekli "Normal" diyerek) yüksek doğruluk elde etmesine rağmen azınlık olan kritik tehditleri kaçırabilmektedir.¹

Literatürde bu sorunu çözmek için farklı veri dengeleme yaklaşımları geliştirilmiştir. Khan vd. (2024), SMOTE ile Tomek Links yöntemini harmanlayarak Karar Ağaçları ile %96.37'lik mükemmel bir çoklu-sınıflandırma (multiclass) başarısı yakalamıştır.⁷ Buna karşılık, Lawal vd. (2025) hesaplama maliyetini düşürmek amacıyla alt örnekleme (undersampling) metoduna başvurarak XGBoost modeliyle %96 oranında dengeli bir F1-Skoru sağlamışlardır.³

3. Materyal ve Yöntem: Uygulamaya Başlangıç

Bu bölümde, projenin teorik altyapısından pratik uygulama safhasına geçiş adımları detaylandırılmaktadır. Kullanılan veri setinin yapısal analizinden başlanarak, makine öğrenmesi algoritmalarının verimli bir şekilde eğitilebilmesi için uygulanan veri ön işleme (preprocessing) ve boyut indirgeme stratejileri ele alınmıştır.¹

3.1. CSE-CIC-IDS2018 Veri Setinin Seçim Rasyonalitesi ve Karakteristikleri

Proje kapsamında, modern ağ tehditlerini gerçekçi bir bulut mimarisinde simüle eden CSE-CIC-IDS2018 veri seti geliştirme ortamına aktarılmıştır. Yaklaşık 16.2 milyon ağ akış (network flow) kaydı işleme potansiyeli sunan bu devasa veri seti, her bir kayıt için paket boyutları, varış süreleri ve bayrak dağılımları gibi 80'den fazla istatistiksel öznitelik barındırmaktadır.¹ Veri setinin en belirgin karakteristik özelliği, normal trafik ile siber saldırı trafiği arasındaki devasa sınıf dengesizliğidir. Azınlık sınıfların bu denli az olması, veri ön işleme safhasında müdahaleyi zorunlu kılmaktadır.

3.2. Veri Ön İşleme Boru Hattı (Data Preprocessing Pipeline)

Saniyede milyonlarca kayıt üreten ağ trafiği verileri, dönüşüm işlemleri esnasında oluşan donanımsal veya algoritmik hatalar nedeniyle gürültü ve eksiklikler barındırır. Bu nedenle, ham veri (Raw PCAP) model eğitime sokulmadan önce kapsamlı bir temizlik boru hattından (Tablo 2) geçirilmiştir.¹

Tablo 2: Veri Ön İşleme Boru Hattı (Pipeline) Akışı

Aşama	İşlem Adımı	Uygulama Nedeni
1. Veri Temizleme	NaN ve Inf Değerlerin Silinmesi	Algoritmaların matematiksel hesaplama hataları vermesini (exception) engellemek.
2. Tekrarlı Veri Ayıklama	Duplicate Satırların Çıkarılması	Modelin tek bir saldırı desenini ezberlemesini (memorization/overfitting) önlemek.

3. Veri Dönüşümü	Label ve One-Hot Encoding	Kategorik ağ protokollerini (TCP/UDP) makinenin anlayabileceği sayısal matrislere çevirmek.
4. Ölçeklendirme	Min-Max Scaler (0-1 Aralığı)	Büyük değerli özniteliklerin (örn: akış süresi), model kararlarını domine etmesini (bias) engellemek.
5. Sınıf Dengeleme	SMOTE / Undersampling	Modelin yalnızca %83'lük normal trafiği öğrenip nadir saldırılara karşı körleşmesini engellemek.

3.3. Boyut İndirgeme ve Öznitelik Seçimi (Feature Selection) Stratejisi

Veri setinde yer alan 80 özniteliğin tamamının sınıflandırma sürecine dâhil edilmesi, "boyutsallık lanetini" (curse of dimensionality) tetikleyerek hesaplama süresini uzatmaktadır. Sinyali gürültüden ayırmak amacıyla, Bilgi Kazancı (Information Gain) ve Korelasyon analizi testleri uygulanarak yalnızca hedef değişkenle (saldırı var/yok) en güçlü istatistiksel ilişkiye sahip öznitelikler seçilmiştir.¹ Karar ağacı tabanlı modellerde kullanılan bu yaklaşım, model performansını artırırken yanlış alarm oranlarını ciddi oranda düşürmektedir. Abbas vd. (2023) tarafından vurgulandığı üzere, algoritmaların karar alma mekanizmasına gömülü özellik seçiciler kullanmak, sistem genelinde %99.9 gibi evrensel doğruluklara olanak tanır.⁸

3.4. SMOTE ile Sentetik Veri Artırma ve Sınıf Dengeleme

Veri setindeki normal kayıtların saldırı kayıtlarına karşı kurduğu üstünlük, makine öğrenmesi modellerinin yalnızca çoğunluk sınıfını öğrenmesine neden olur. Bu engeli aşmak için, veri dengeleme literatürünün en güçlü araçlarından biri olan Sentetik Azınlık Aşırı Örnekleme Tekniği (SMOTE) kullanılarak azınlık saldırı sınıflarının matematiksel olarak geçerli kopyaları üretilmiş ve sınıflar arası adalet sağlanmıştır.¹

4. Sistem Mimarisi ve Algoritmik Çerçeve

Modern NIDS çözümlerinde tekil (single) karar mekanizmaları yerine, birden çok ağacın tahmin gücünü birleştiren Topluluk Öğrenme (Ensemble Learning) mimarileri endüstri standardı kabul edilmektedir. Bu projede, birbirine zıt ama tamamlayıcı iki temel topluluk felsefesi olan Bagging ve Boosting yaklaşımları üzerinden kıyaslamalı bir model mimarisi kurulacaktır.

4.1. Bagging Yaklaşımı: Rastgele Orman (Random Forest)

Rastgele Orman (RF), eğitim veri setinden rastgele alt kümeler oluşturan ve her bir küme üzerinde paralel, bağımsız karar ağaçları inşa eden bir "Bootstrap Aggregating" (Bagging) algoritmasıdır. NIDS bağlamında RF'nin en büyük avantajı, sınıflandırma sırasında ağaçların "çoğunluk oylaması" (majority voting) mekanizmasını kullanması sayesinde varyansı düşürmesi ve gürültülü (noisy) ağ trafiği verilerine karşı olağanüstü bir direnç göstermesidir.¹ Brute Force veya Port Tarama gibi özellik çizgileri belirgin olan saldırılarda yüksek stabilite sunar. Eksik özniteliklere sahip verilerde dahi model tahmin gücünü koruyabilmektedir.

4.2. Boosting Yaklaşımı: Ekstrem Gradyan Artırma (XGBoost)

Bagging mantığının aksine XGBoost, zayıf öğrencilerin (sık karar ağaçlarının) art arda kurulduğu ve her yeni ağacın bir önceki ağacın hatalarını (rezidüellerini) gradyan düşüşü yoluyla düzeltecek şekilde eğitildiği bir "Boosting" algoritmasıdır. XGBoost'un projemiz için en kritik özelliği; içerdiği algoritmik donanım sayesinde devasa veri setlerinde sunduğu yüksek bellek yönetimi, paralel işlem hızı ve sınıf ağırlıklandırma (imbalance handling) yeteneğidir.¹ CSE-CIC-IDS2018 veri setinde XGBoost algoritması, karar ağaçlarının esnekliğini L1 ve L2 düzenlileştirmeleri (regularization) ile birleştirerek ezberlemeyi önler.

Tablo 3: CSE-CIC-IDS2018 Üzerinde Algoritmaların Karşılaştırmalı Performans Analizi (Alenezi vd. 2024 Referanslı)

Metrik / Özellik	Random Forest (Bagging)	XGBoost (Boosting)
Genel Doğruluk (Accuracy)	%99.40	%99.80
ROC - AUC Skoru	Mükemmele Yakın	Mükemmele Yakın
Çıkarım Süresi (Inference Time)	7.42 Saniye	6.36 Saniye
İşlem Verimliliği	Standart	RF'ye Göre %14 Daha Hızlı
Gerçek Zamanlı Tespit Uygunluğu	Orta / Yüksek	Çok Yüksek

Yukarıdaki Tablo 3'te Alenezi vd. (2024) tarafından yapılan çalışmanın bulgularından da görüleceği üzere, XGBoost algoritması yalnızca tehdit tespiti (%99.80) konusunda değil, aynı zamanda büyük ölçekli bir test verisindeki reaksiyon süresi (6.36 saniye) bakımından da Random Forest'a karşı %14'lük operasyonel bir üstünlük sağlamaktadır. Bu bulgular, Boosting tabanlı algoritmaların gerçek zamanlı anomali tespit sistemleri (RT-NIDS) için daha ideal bir altyapı sunduğunu pekiştirmektedir.

5. Deneysel Kurulum ve Değerlendirme Metrikleri

Makine öğrenmesi modellerinin başarısı, sınıf dengesizliğinin yarattığı istatistiksel engelleri aşabilecek kadar sağlam matematiksel ölçütlerle değerlendirilmelidir.

5.1. Performans Ölçütleri (Doğruluk, Duyarlılık, Kesinlik ve F1-Skoru)

Siber güvenlik analizlerinde model başarısı yalnızca Doğruluk (Accuracy) ile ölçülmemelidir. Bunun yerine aşağıdaki metrikler merkeze alınacaktır:¹

- **Duyarlılık (Recall / True Positive Rate):** Gerçek saldırıların (True Positive) ne kadarının model tarafından başarıyla tespit edildiğini gösterir. Sisteme sızan bir saldırının fark edilememesi (False Negative) büyük felaketlere yol açacağından NIDS için en hayati metriktir.
- **Kesinlik (Precision):** Modelin "saldırı" olarak işaretlediği paketlerin ne kadarının gerçekten saldırı olduğunu ifade eder. Düşük kesinlik, yüksek sahte alarm (False Positive) üreterek sistem yöneticilerinin operasyonel yorgunluk yaşamasına neden olur.
- **F1-Skoru:** Kesinlik ve Duyarlılığın harmonik ortalamasıdır. Dengesiz veri setlerinde modelin gerçek ve dengeli performansını gösteren en güvenilir ölçüttür. Projemizde hedeflenen F1-Skoru ~%97 civarındadır.¹

5.2. Beklenen Operasyonel Çıktılar ve Doğruluk Yanılgısının Aşılması

Milyonlarca normal paketin aktığı ve saldırıların yalnızca azınlıkta kaldığı ağ ortamlarında, sistemi "kör" bırakan bir model bile tüm trafiğe "Normal" diyerek yüksek Doğruluk (Accuracy) elde etmiş gibi görünebilir.¹ "Doğruluk Yanılgısı" (Accuracy Paradox) olarak adlandırılan bu durumu aşmak, projemizin temel gayelerinden biridir. Geliştirilen Random Forest ve XGBoost modellerinin, güvenlik riskini (kaçırılan saldırıları) ve operasyonel yükü (yanlış alarmları) dengeleyerek "Optimum Operasyonel Bölge" içerisinde çalışması hedeflenmektedir.¹

6. Sonuç

Bu çalışmada, siber tehditlerin otonom tespiti için makine öğrenmesi algoritmalarının yetkinlikleri analiz edilmiş ve uygulanacak metodolojinin teorik-teknik mimarisi tamamlanmıştır. CSE-CIC-IDS2018 veri setinin temizlenmesi, kategorik özelliklerin dönüştürülmesi, özellik seçimi ile sinyalin gürültüden ayrıştırılması ve SMOTE ile sınıf dengesizliğinin giderilmesi, ağaç tabanlı (RF ve XGBoost) topluluk algoritmalarının yüksek performans göstermesi için kritik bir zemin hazırlamıştır. Gerçekleştirilen bu derinlemesine analiz, NIDS modellerinde salt doğruluk metriğinin yanıltıcı olabileceğini; sistem güvenliğinin ancak Duyarlılık (Recall) ve Kesinlik (Precision) metriklerinin optimum dengede tutulmasıyla sağlanabileceğini bilimsel olarak ortaya koymuştur.

7. Gelecek Planları ve Araştırma Yönelimleri

Geliştirdiğimiz statik makine öğrenmesi tabanlı anomali tespit mimarisinin, sürekli evrilen siber tehdit ortamında güncelliğini ve esnekliğini koruyabilmesi adına projenin ilerleyen fazlarında çeşitli yenilikçi teknolojilerin sisteme entegre edilmesi planlanmaktadır. Belirlenen ana araştırma ve geliştirme hedefleri şunlardır:

7.1. Derin Öğrenme ve Zamansal (Temporal) Analiz Entegrasyonu

Mevcut XGBoost ve Random Forest modelleri ağ akışlarını tekil (izole) paketler olarak değerlendirmekte yüksek başarı sağlasa da, sinsi APT (Gelişmiş Kalıcı Tehdit) saldırıları zaman içerisinde düşük hacimlerle gerçekleşebilmektedir. Gelecek çalışmalarda, verinin zamansal sıralamasını ve hafızasını analiz edebilen **Uzun-Kısa Süreli Bellek (LSTM - Long Short-Term Memory)** veya Gated Recurrent Unit (GRU) gibi dizilim tabanlı derin öğrenme ağlarının mevcut mimariye entegre edilmesi hedeflenmektedir.¹ Bu sayede saldırıların zaman içindeki ritimleri daha keskin bir şekilde saptanacaktır.

7.2. Yazılım Tanımlı Ağlar (SDN) ve Sınır Bilişim (Edge Computing)

Geliştirilen makine öğrenmesi modelleri genellikle merkezi bir sunucuda çalışmaktadır. Gelecek projeksiyonunda bu zeki analiz motorunun, ağ kontrolünü veri akışından ayıran **Yazılım Tanımlı Ağ (SDN)** denetleyicilerine entegre edilmesi hedeflenmektedir.¹ SDN entegrasyonu sayesinde NIDS sadece bir "tespit" (detection) mekanizması olmaktan çıkıp, anomali anında saldırgan portunu otonom olarak kapatan bir "önleme" (prevention) mekanizmasına dönüşecektir. Ek olarak analiz yükü, buluttan alınıp yönlendiricilerin (router) bulunduğu uç noktalara (Edge Computing) taşınarak sıfır gecikmeli (zero-latency) bir savunma ağı kurulacaktır.¹

7.3. Açıklanabilir Yapay Zeka (XAI) ile Karar Şeffaflığı

Siber güvenlik analistlerinin (SOC ekipleri) makine öğrenmesi modellerinin ürettiği alarmlara güvenebilmesi için modelin neden alarm ürettiğini bilmesi şarttır. "Kara kutu" (black-box) olarak çalışan XGBoost ve Random Forest algoritmalarına, gelecekte **SHAP (SHapley Additive exPlanations)** ve **LIME (Local Interpretable Model-agnostic Explanations)** gibi Açıklanabilir Yapay Zeka (XAI) kütüphaneleri entegre edilecektir. Bu sayede modelin bir ağ trafiğine "Saldırı" demesinin arkasında yatan en kritik 3 özelliğin (örneğin: Paket boyutu çok büyük, SYN bayrağı frekansı yüksek vb.) analiste doğrudan raporlanması sağlanacaktır.

7.4. Çekişmeli Makine Öğrenmesi ve Model Dayanıklılığı

Saldırganlar, makine öğrenmesi tabanlı NIDS'leri atlatabilmek için ağ paketlerine mikroskobik manipülasyonlar ekleyerek Adversarial Attacks düzenleyebilmektedir. Geliştirilen sistemin bu tür manipülasyonlara karşı ne kadar dirençli olduğunun test edilmesi ve modele Adversarial Training uygulanarak sahte verilere karşı dayanıklılığının artırılması, sistemin uzun vadeli güvenliği için atılacak kritik bir diğer adımdır.

8. Kaynakça (References)

1. H. İ. Coşar, Ç. Arısoy, ve H. Ulutaş, "Intrusion Detection on CSE-CIC-IDS2018 Dataset Using Machine Learning Methods," *Artificial Intelligence Theory and Applications*, cilt 4, sayı 2, ss. 143-154, 2024.
2. W. Lawal, P. O. Erumi, K. B. Adedeji, ve I. A. Makinde, "A Comparative Analysis of Machine Learning Models for Intrusion Detection using the CSE-CIC-IDS2018 Dataset," *NIPES Journal of Science and Technology Research*, cilt 7, ss. 850–858, Eki. 2025.
3. Q. Abbas, S. Hina, H. Sajjad, K. S. Zaidi, ve R. Akbar, "Optimization of predictive performance of intrusion detection system using hybrid ensemble model for secure systems," *PeerJ Computer Science*, e1552, Eyl. 2023.
4. F. A. Khan, A. A. Shah, N. Alshammry, S. Saif, W. Khan, M. O. Malik, ve Z. Ullah, "Balanced Multi-Class Network Intrusion Detection Using Machine Learning," *IEEE Access*, cilt 12, ss. 178222 - 178236, Kas. 2024.
5. P. Castro, F. Santos, ve P. Lopes, "Comparative Analysis of Supervised and Unsupervised Learning for Intrusion Detection in Network Logs," *Computation*, cilt 14, sayı 4, s. 92, Nis. 2026.
6. F. A. Rafrastara, G. F. Shidik, W. Khozi, N. Rijati, ve O. Setiono, "Tree-Based Ensemble Algorithms and Feature Selection Method for Intelligent Distributed Denial of Service Attack Detection," *Journal of Cyber Security and Mobility*, cilt 14, sayı 1, Oca. 2025.
7. M. S. Soumik, "A comparative analysis of Network Intrusion Detection (NID) using Artificial Intelligence techniques for increase network security," *International Journal of Science and Research Archive*, cilt 13, sayı 2, ss. 4014–4025, Ara. 2024.
8. M. N. Alenezi vd., "Comparative Analysis of Random Forest and Xgboost Performance for Network Flow-Based Malware Classification," *CSE-CIC-IDS2018 Evaluation*, 2024.

8.1. Alıntılanan Çalışmalar

1. ML_Network_Anomaly_Detection.pdf
2. Intrusion Detection on CSE-CIC-IDS2018 Dataset Using ... - DergiPark, erişim tarihi Nisan 16, 2026, <https://dergipark.org.tr/en/download/article-file/4230736>
3. (PDF) A Comparative Analysis of Machine Learning Models for ..., erişim tarihi Nisan 16, 2026, https://www.researchgate.net/publication/400061307_A_Comparative_Analysis_of_Machine_Learning_Models_for_Intrusion_Detection_using_the_CSE-CIC-IDS2018_Dataset
4. Comparative Analysis of Supervised and Unsupervised Learning for ..., erişim tarihi Nisan 16, 2026, <https://www.mdpi.com/2079-3197/14/4/92>
5. Tree-Based Ensemble Algorithms and Feature Selection Method for ..., erişim tarihi Nisan 16, 2026, <https://ieeexplore.ieee.org/document/10975154/>
6. A comparative analysis of Network Intrusion Detection (NID) using ..., erişim tarihi Nisan 16, 2026, https://ijsra.net/sites/default/files/fulltext_pdf/IJSRA-2024-2664.pdf
7. Balanced Multi-Class Network Intrusion Detection Using Machine ..., erişim tarihi Nisan 16, 2026, <https://ieeexplore.ieee.org/document/10758423/>
8. Optimization of predictive performance of intrusion detection system using hybrid ensemble model for secure systems - PeerJ, erişim tarihi Nisan 16, 2026, <https://peerj.com/articles/cs-1552/>