


Ağ Anomali Tespiti

Makine Öğrenmesi — Proje Raporu 2 · Eskişehir Osmangazi Üniversitesi Mühendislik
Mimarlık Fakültesi

Grup 6 · Çağrı Elagöz · Yusuf Özgöçmen · 2025–2026 Bahar





Neden Anomali Tespiti?

Anomali tespiti, ağ trafiğinde beklenen normal davranıştan sapmaları yakalayıp şüpheli etkinlikleri erken aşamada belirleme yöntemidir. İmza tabanlı yaklaşımlar yalnızca bilinen saldırıları eşleştirebildiği için, yeni tehditler ve değişken saldırı kalıpları karşısında sınırlı kalır.

Bu projede amaç, ağ verisindeki olağandışı örüntüleri makine öğrenmesi ile modelleyip saldırı olasılığı taşıyan trafiği otomatik olarak işaretlemektir. ML, elle yazılmış kurallara göre daha esnek çalışır; hız, akış süresi, paket boyutu ve bayrak dağılımı gibi özelliklerden karmaşık ilişkileri öğrenerek bilinmeyen anormallikleri daha pratik biçimde tespit etmeyi sağlar.

CSE-CIC-IDS2018 Veri Seti



Neden Bu Veri Seti?

Amazon AWS ortamında simüle edilen bu veri seti, **16,2 milyondan fazla** ağ akışı kaydı ve **80'den fazla** istatistiksel öznitelik barındırır. Modern DDoS, Brute Force ve Botnet saldırılarını içerir.

- ❏ Donanım kısıtları nedeniyle tüm veri işlenmeyecek; veri setinden temsilci bir **alt küme** oluşturulacaktır.

Veri Ön İşleme Boru Hattı

Ham ağ verisi, model eğitiminden önce temizlenir, dönüştürülür, ölçeklenir ve dengelenir.

1. Temizleme + Tekrar

NaN, **Inf** ve aykırı değerler ayıklanır; özdeş kayıtlar kaldırılır.

2. Kategorik Dönüşüm

Kategorikler **Label** veya **One-Hot Encoding** ile sayısallaştırılır.

3. Ölçeklendirme

Min-Max ile özellikler `[0,1]` aralığına çekilir.

4. Sınıf Dengeleme

SMOTE ile azınlık sınıf için sentetik örnekler üretilir.

Bu adımlar, veriyi modelleme için daha tutarlı ve dengeli hâle getirir.

Boyut İndirgeme: 80+ Sütundan 15-20'ye

Boyutsallık Laneti

80+ özniteliğin tamamı hesaplama süresini uzatır ve gürültü ekler.

Bilgi Kazancı (Information Gain) ve korelasyon analizi ile yalnızca en ayırt edici öznitelikler seçilecektir.



Hedef

80+ → 15-20 öznitelik

Yöntem

Information Gain + Korelasyon filtresi

Sınıf Dengesizliđi ve SMOTE



Sorun

Veri setinde normal trafik baskın; model sürekli "Normal" diyerek yüksek doğruluk elde edebilir ama saldırıları kaçıırır (**Accuracy Paradox**).

Çözüm: SMOTE

Sentetik Azınlık Aşırı Örnekleme Tekniđi ile azınlık saldırı sınıflarının matematiksel olarak geçerli kopyaları üretilir. Alternatif olarak **Undersampling** da değerlendirilecektir.

 Hedef: F1-Skoru $\approx$ %97

Algoritma 1: Random Forest (Bagging)

Neden Bu Projede?

- Ağ trafiğinde hem sayısal hem de kategorik özniteliklerle iyi çalışır
- Doğrusal olmayan anomali örüntülerini yakalamada güçlüdür
- Az gürültüyle yüksek genellenebilirlik sağlar; gerçek zamanlı sınıflandırma için uygundur

Beklenen Etki

Normal trafik ile saldırı örnekleri arasındaki karmaşık sınırları ayırarak yanlış alarmları dengeler ve özellikle karma saldırı senaryolarında daha kararlı sonuç üretir.

Nasıl Kullanacağız?

1. **Veri akışı:** Ön işlenmiş trafik kayıtları eğitim/test ayırımına alınır; eksik değerler ve ölçekleme adımları tamamlanır.
2. **Eğitim:** Model, eğitim verisi üzerinde bootstrap örnekleme ile çok sayıda ağaç kuracak şekilde eğitilir.
3. **Hiperparametreler:** `n_estimators`, `max_depth`, `max_features`, `min_samples_split` ve `class_weight` ayarlanır.
4. **Değerlendirme:** F1-Skoru, recall ve confusion matrix üzerinden saldırı yakalama başarısı izlenir.

Beklenen Performans

- Yüksek recall ile saldırı kaçırma riskini azaltır
- Overfitting'e karşı tek ağaca göre daha dayanıklıdır
- Özellik önem skorlarıyla hangi trafik sinyallerinin belirleyici olduğu görülebilir

Algoritma 2: XGBoost (Boosting)

Bu projede neden XGBoost?

- Random Forest'a göre hata odaklı öğrenme ile daha yüksek ayırt edicilik sağlar
- İnce ayarlı hiperparametrelerle proje verisine daha iyi uyum sağlar
- Dengesiz sınıflarda ağırlıklandırma ve regularization ile kontrollü sonuç üretir

Beklenen performans

- Daha yüksek doğruluk ve F1-score
- Yanlış pozitifleri azaltmada daha dengeli davranış

Teknik kullanım planı

1. Veri ön işleme: eksik değer kontrolü, kategorik değişken kodlama, ölçekleme ihtiyacına göre hazırlık
2. Eğitim: train/validation ayrımı ve erken durdurma ile aşırı uyumu izleme
3. Hiperparametre ayarı: **n_estimators**, **max_depth**, **learning_rate**, **subsample**, **colsample_bytree**, **reg_alpha**, **reg_lambda**



Değerlendirme Metrikleri ve Beklenen Zorluklar

Performans Ölçütleri

Duyarlılık (Recall)

Gerçek saldırıların ne kadarının tespit edildiği — NIDS için en kritik metrik.

Kesinlik (Precision)

"Saldırı" işaretlenenlerin gerçekte saldırı olma oranı; sahte alarmı minimize eder.

F1-Skoru

Harmonik ortalama; dengesiz veri setlerinde en güvenilir ölçüt.
Hedef: ~%97

Karşılaşılabilecek Zorluklar

- **Donanım kısıtı:** 16,2M kayıt tam işlenemeyecek, alt küme zorunlu
- **Sınıf dengesizliği:** Azınlık saldırı sınıflarının yeterince temsil edilmemesi
- **Aşırı öğrenme:** Modelin saldırı desenlerini ezberlemesi (overfitting)
- **Doğruluk yanılgısı:** Yüksek Accuracy'nin gerçek performansı gizlemesi

Sonuç ve Gelecek Planları

01

Model Eğitimi ve Hiperparametre Tuning

Grid Search ve Cross-Validation ile en uygun model ayarları belirlenecek.

02

Model Karşılaştırması

Random Forest ve XGBoost modellerinin performansı karşılaştırılarak en iyi yaklaşım seçilecek.

03

Test Seti Değerlendirmesi

Bağımsız test seti üzerinde sonuçlar ölçülecek ve Confusion Matrix ile hata türleri incelenecek.

04

Model Kaydetme ve Deployment Hazırlığı

Seçilen model kaydedilecek, temel entegrasyon ve kullanım adımları deployment için hazırlanacak.